

Index Creation

Sven Fiergolla

25. März 2018

Übersicht

Einführung

hardware constraints

Index Creation

- Blocked sort-based indexing

- Single-pass in-memory indexing

- Distributed indexing

- Dynamic indexing

- andere Indexverfahren

Fazit

Quellen

Einführung

Effiziente Suche über:

Sammlung von Büchern
das Web
andere große Datenmengen

zu viel für Main Memory!

Einführung

Effiziente Suche über:

Sammlung von Büchern
das Web
andere große Datenmengen

zu viel für Main Memory!

Einführung

Typische Systemeigenschaften (stand 2018)

- ▶ *clock rate* 2-4 GHz, 4-8 Kerne
- ▶ *main memory* 4-32 GB
- ▶ *disk space* ≤ 1 TB SSD oder ≥ 1 TB HDD
 - ▶ HDD (hard disk drive)
 - ▶ *average seek time* zwischen 2 und 20 ms
 - ▶ *transfer time* 150 - 300 MB/s
 - ▶ SSD (solid state disk)
 - ▶ *average seek time* zwischen 0.08 und 0.16 ms
 - ▶ *transfer time* Lesen: 545 MB/s, Schreiben: 525 MB/s

Einführung

Typische Systemeigenschaften (stand 2018)

- ▶ *clock rate* 2-4 GHz, 4-8 Kerne
- ▶ *main memory* 4-32 GB
- ▶ *disk space* ≤ 1 TB SSD oder ≥ 1 TB HDD
 - ▶ HDD (hard disk drive)
 - ▶ *average seek time* zwischen 2 und 20 ms
 - ▶ *transfer time* 150 - 300 MB/s
 - ▶ SSD (solid state disk)
 - ▶ *average seek time* zwischen 0.08 und 0.16 ms
 - ▶ *transfer time* Lesen: 545 MB/s, Schreiben: 525 MB/s


Einführung

Typische Systemeigenschaften (stand 2018)

- ▶ *clock rate* 2-4 GHz, 4-8 Kerne
- ▶ *main memory* 4-32 GB
- ▶ *disk space* ≤ 1 TB SSD oder ≥ 1 TB HDD
 - ▶ HDD (hard disk drive)
 - ▶ *average seek time* zwischen 2 und 20 ms
 - ▶ *transfer time* 150 - 300 MB/s
 - ▶ SSD (solid state disk)
 - ▶ *average seek time* zwischen 0.08 und 0.16 ms
 - ▶ *transfer time* Lesen: 545 MB/s, Schreiben: 525 MB/s

hardware constraints

Indizierung einer Sammlung von Daten auf der Festplatte



Zugriffszeit auf Festplatte als Bottleneck

Index Creation

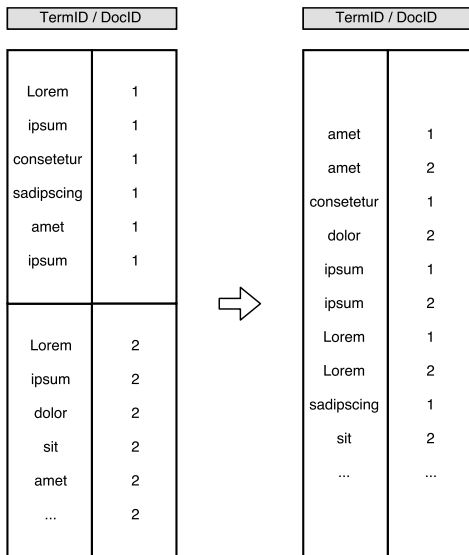
geeignete Datenstruktur um Zugriff auf die Festplatte zu minimieren

TermID / DocID

Lorem	1
ipsum	1
consetetur	1
sadipscing	1
amet	1
...	1
Lorem	2
ipsum	2
dolor	2
sit	2
amet	2
...	2

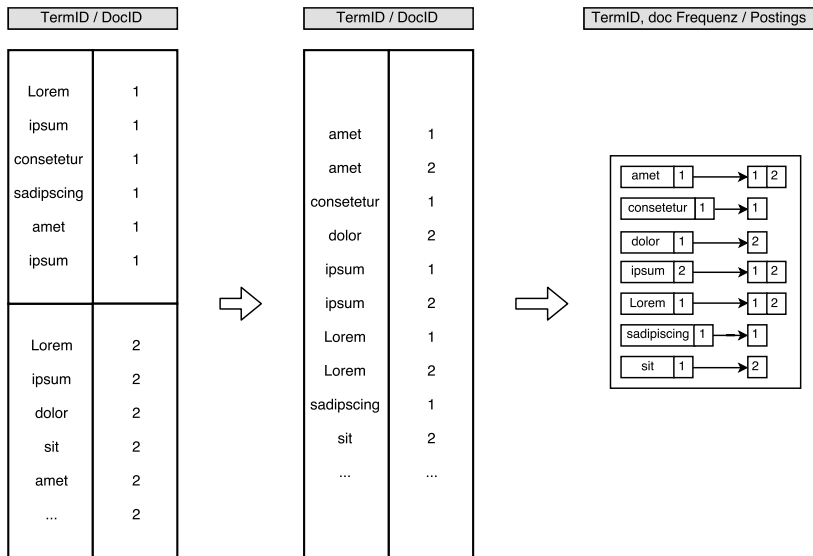
Index Creation

geeignete Datenstruktur um Zugriff auf die Festplatte zu minimieren



Index Creation

geeignete Datenstruktur um Zugriff auf die Festplatte zu minimieren



Index Creation - hardware constraints

in der Regel übersteigt die Datenmenge der Dokumente den Main Memory.

Reuters-RCV1 benötigt ca 0.8 GB für die termID/DocID Paare, bereits die DBLP übersteigt die Dokumentenanzahl, besitzt jedoch weniger Terme.

Blocked sort-based indexing (BSI)


Lösung:

- ▶ Sammlung von Dokumenten in einzelne Blocks unterteilen
- ▶ Index über einzelne Blöcke erstellen
- ▶ Teilindizes mergen

```
n = 0;  
while all documents have not been  
processed do  
    n = n + 1;  
    block = ParseNextBlock();  
    BSBI-INVERT(block);  
    WriteBlockToDisk(block,  $f_n$ );  
end  
MergeBlocks( $f_1, \dots, f_n; f_{merged}$ );  
Algorithm 1: BSI Algorithmus
```

Blocked sort-based indexing (BSI) - merging Blocks


Zusammenführen von
Postings Lists bei
block sort-based
Indexing



Blocked sort-based indexing (BSI) - merging Blocks

Zusammenführen von
Postings Lists bei
block sort-based
Indexing

amet	d1,d2	consetetur	d3, d4
dolor	d2	Lorem	d3
Lorem	d1	ipsum	d3
ipsum	d2	sit	d4




Blocked sort-based indexing (BSI) - merging Blocks


Zusammenführen von
Postings Lists bei
block sort-based
Indexing

amet	d1,d2
dolor	d2
Lorem	d1
ipsum	d2

consetetur	d3, d4
Lorem	d3
ipsum	d3
sit	d4




amet	d1,d2
consetetur	d3,d4
dolor	d2
Lorem	d1, d3
ipsum	d2, d3
sit	d4



Blocked sort-based indexing (BSI) - merging Blocks

Zusammenführen von
Postings Lists bei
block sort-based
Indexing

amet	d1,d2
consetetur	d3,d4
dolor	d2
Lorem	d1, d3
ipsum	d2, d3
sit	d4



Blocked sort-based indexing (BSI) - Fazit

Fazit zu BSBI:

- ▶ Zeitkomplexität: $\Theta(T \cdot \log(T))$
 - ▶ das Sortieren hat die höchste Komplexität
 - ▶ das Parsen und Mergen der Blocks ist jedoch in der Regel am Zeitaufwendigsten
- ▶ Datenstruktur für Mapping zwischen termen und termID's muss in Main Memory liegen
 - ▶ kann für sehr große Datenmengen auch Server überlasten

Single-pass in-memory indexing (SPIMI)

- ▶ einzelne dictionaries für jeden Block
 - ▶ keine Datenstruktur für das Mapping von termen und termID's
- ▶ kein Sortieren der einzelnen Blöcke
 - ▶ Postings in der Reihenfolge ihres Vorkommens in die Postingslist aufnehmen
 - ▶ PostingsList sollte jedoch sortiert werden, da dann auf Sortieren/Suchen beim mergen der Blöcke verzichtet werden kann

Single-pass in-memory indexing (SPIMI)

SPIMI-invert(TokenStream)

outputFile = new HashFile();

dictionary = new HashFile();

while *free memory available* **do**

 token = next(TokenStream) **if** *term(token)* \notin *dictionary* **then**

 | PostingsList = AddToDictionary(dictionary, term(token));

else

 | PostingsList = GetPostingsList(dictionary, term(token));

end

if *full(PostingsList)* **then**

 | PostingsList = DoublePostingsList(dictionary, term(token));

 AddToPostingsList(PostingsList, docID(token));

 SortedTerms = SortTerms(dictionary);

 WriteBlockToDisk(SortedTerms, dictionary, OutputFile);

end

Algorithm 2: SPIMI-invert Algorithmus


Single-pass in-memory indexing (SPIMI)

Vorteile gegenüber BSI:

- ▶ kann für beliebig große Datenmengen einen Index erstellen, solange das Festplattenvolumen nicht überstiegen wird
- ▶ einzelne Blöcke können größer sein
 - ▶ Indexerstellung effizienter
- ▶ Dictionaries und die erstellte PostingsList kann durch Kompression kompakt auf der Festplatte gespeichert werden

Distributed indexing


- ▶ manche Sammlungen übersteigen die Leistung eines einzelnen Rechners
 - ▶ beispielsweise das Web
- ▶ um Indizes über solche Sammlungen zu erstellen, muss die arbeit auf mehrere Rechner verteilt werden




Distributed indexing - MapReduce




Distributed indexing - MapReduce




Distributed indexing - MapReduce



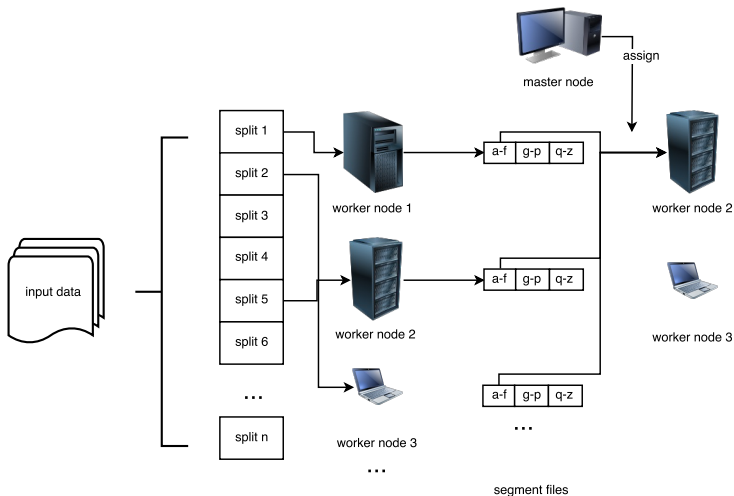
Distributed indexing - MapReduce



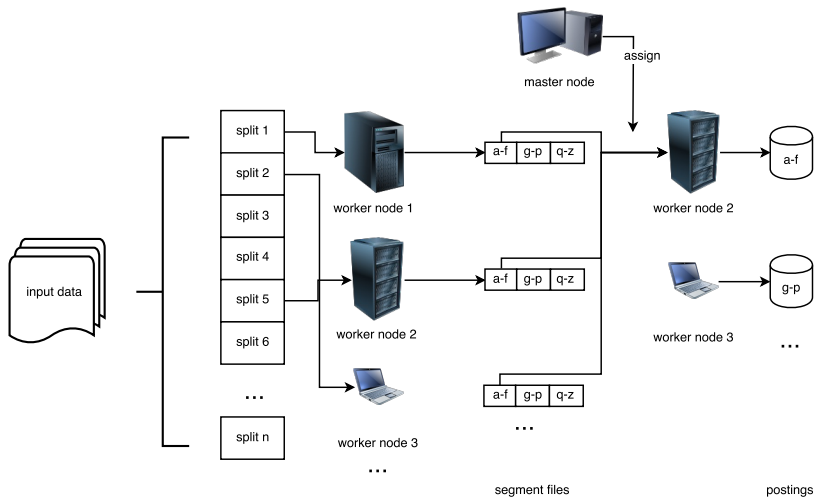
Distributed indexing - MapReduce



Distributed indexing - MapReduce



Distributed indexing - MapReduce



Distributed indexing - Fazit

todo

Dynamic indexing

todo

Quellen

- ▶ Christopher D. Manning, Prabhakar Raghavan and Hinrich Schütze
„Introduction to Information Retrieval“ Cambridge University Press 2008, pp.
1-18 and 67-84. ¹

¹<https://nlp.stanford.edu/IR-book/pdf/04const.pdf>